

GCI Winter 2023

最終課題

モバイルPOSの市場分析

世界のモバイルPOS市場の動向

図1 2023年から2030年にかけての
年間平均成長率(CAGR)の予測

市場	世界規模の CAGR(%)	アメリカの CAGR(%)
POS全体	8.3	6.1
モバイルPOS	11.1	9.3

POS全体とモバイルPOSのCAGRを比較し
世界のモバイルPOS市場の動向を調査

図1をみると2023年～2030年にかけて
世界規模・アメリカ共にPOS全体に比べ
モバイルPOSのCAGRの方が高いと分かる


すなわち世界の動向として
モバイルPOSの需要が高まっている
と推測することができる

モバイルPOSの成長要因として

- ・ 電子決済の普及
 - ・ 導入が低コスト
 - ・ 顧客満足度の高さ
- などが挙げられる

国内の“モバイルPOS” 検索数の推移

図2 国内“モバイルPOS” 検索数の推移(人気度)
(上:元データ 下:トレンド成分)



引用：(閲覧：2024/01/02)

<https://trends.google.co.jp/trends/explore?date=2017-01-01%202023-01-01&geo=JP&q=%E3%83%A2%E3%83%90%E3%82%A4%E3%83%ABPOS&hl=ja>

国内のモバイルPOSの需要を調査するため
2017年1月1日～2023年1月1日における
国内の“モバイルPOS” 検索数の推移を調査

図2下よりトレンド成分は上昇傾向なので
年々“モバイルPOS” 検索数が増えている

すなわち


国内でもモバイルPOSの需要が高まっている
と推測することができる

トレンド成分：

- ・ 長期的な変動や傾向を表す要素
- ・ データ全体の増減パターンを示す

国内企業のモバイルPOSに対する認識

図3 国内企業のモバイルPOSの認識(%)



- 調査方法：インターネット調査
- 調査実施期間：2017年8月25日(金)～2017年8月30日(水)
- 有効回答数：500サンプル
- 調査機関：株式会社ネオマーケティング

引用：(閲覧：2024/01/02)
https://jpn.nec.com/mobile-pos/mobile_pos_intention_survey.html

国内企業のモバイルPOSに対する認識について企業の展開規模別に調査

図3よりモバイルPOSの認知度ではそれほど大きな差は見られない


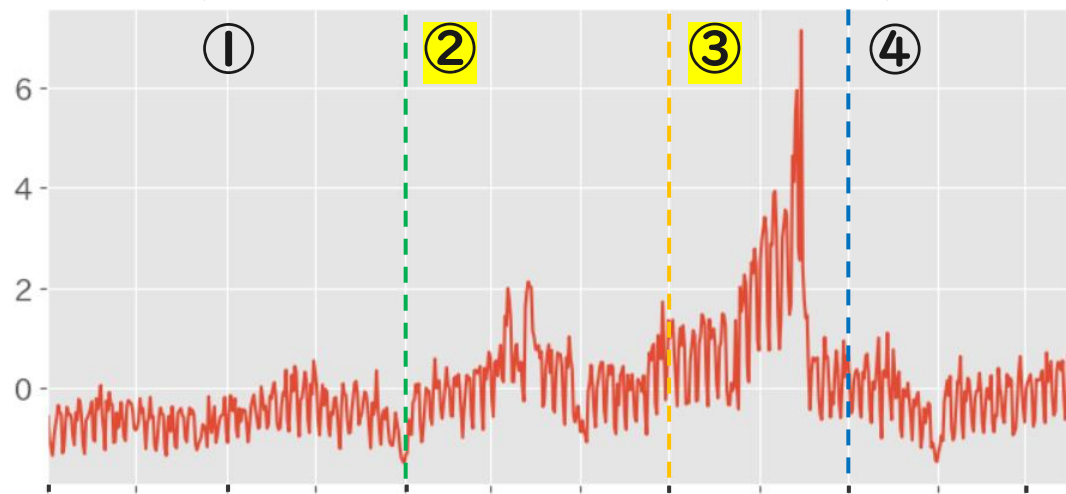
一方、関心度・導入意向では大差がつき
多店舗展開企業の方が関心・導入意向が高い
ことが分かる

すなわち
中・大企業ではモバイルPOSが浸透している
ことが推測される

アカウント獲得数の分析

アカウント獲得数の分析

図4 アカウント獲得数の推移
(上:元データ 下:トレンド成分)



頂いたデータセットのうち最も重要と思われる
アカウント獲得数を対象にデータ分析を実施


期間	トレンド成分において 0を基準としたデータ分布の様子
① 2018年5月～2018年12月	0より下に分布
② 2019年1月～2019年6月	0を上回る
③ 2019年7月～2019年10月	一時的に急上昇
④ 2019年11月～2020年3月	再び0より下に分布

図4下より

①・④の期間においては0を下回るが
②・③の期間においては上回ることが分かる

CM実施合計日数との比較

図5 トレンド成分とCM実施合計日数の比較
(上:トレンド成分 下:CM実施合計日数)



トレンド成分をCM実施合計日数と比較してみる


期間	CM実施合計日数	1か月あたりのCM実施日数
① 2018年3月～2018年12月	22日 (0 → 22)	約2日
② 2019年1月～2019年6月	64日 (22 → 86)	約11日
③ 2019年7月～2019年10月	74日 (86 → 160)	約19日
④ 2019年11月～2020年3月	47日 (160 → 207)	約9日

表を見ると②・③の期間においては
1か月あたりのCM実施日数が多いため
0を上回っていると推測できる

その一方で、具体的にいつCMを実施すると
どれ程のアカウント獲得できるかは不明…

課題と事業提案

以上より
「CMの効果測定」
を課題として採用



事業提案

予測モデルご提供
によるCMの効果測定

事業提案

予測モデルご提供の概要

予測モデルを用いてCMの効果測定



予測日	実施フラグ
2024/2/1	0
2024/2/2	1
2024/2/3	1
2024/2/4	0

⋮



①

弊社提供のWebアプリで
・ 予測したい期間
・ CMを実施する予定日時
をcsv形式で入力

②

弊社が提供する
学習済みの予測モデルで
アカウント獲得数を予測

③

Webアプリで予測を確認,
CMのアカウント獲得効果
を予測結果から測定

導入によるメリット

短期におけるメリット：


- ・最もCM効果が高いタイミングでCMを実施することでアカウント獲得数を最大化できる
- ・広告費を最適に配分できる

中長期におけるメリット：

- ・アカウント獲得数の予測から顧客の行動を予測することでマーケティング戦略の指針として活用できる

実施例：データ前処理

図6 学習データとテストデータ
(差分処理済み)



実施例として

2018/6/9～2020/2/29(631日)を**学習データ**

2020/3/1～2020/3/31 (31日)を**テストデータ**

として1か月のアカウント獲得数を予測 (図6)

以下の3つのデータについては

定常過程にするために差分系列を作った

- ・アカウント獲得数
- ・ヘルプデスク入電数
- ・Google Trend “エアレジ” 検索数(後述)

定常過程：

- ・時系列的に安定性を持つこと。
- ・定常でない場合は予測が難しくなる。

差分系列：

- ・元の系列から直前の値を引いた系列。
- ・差分処理を繰り返すと定常過程になる。


実施例：特徴量作成

頂いたデータセットに追加して
予測精度向上のため以下の特徴量を作成

- 目的変数(acc_get_cnt)に関する特徴量4つ
 - lag1：元データから1期ずらした値
 - lag7：元データから7期ずらした値
 - window7：過去1週間の平均値
 - expanding：過去すべての期間の平均値
- 日曜日フラグ(isSunday)、
- CM実施合計日数(cm_cumsum)、
- トレンドを捉える連番の特徴量(t)、
- 季節性を捉える三角関数特徴量(図7右)

また外部データとして
Google Trendにおける“エアレジ”検索数を追加

図7 最終的なカラム一覧

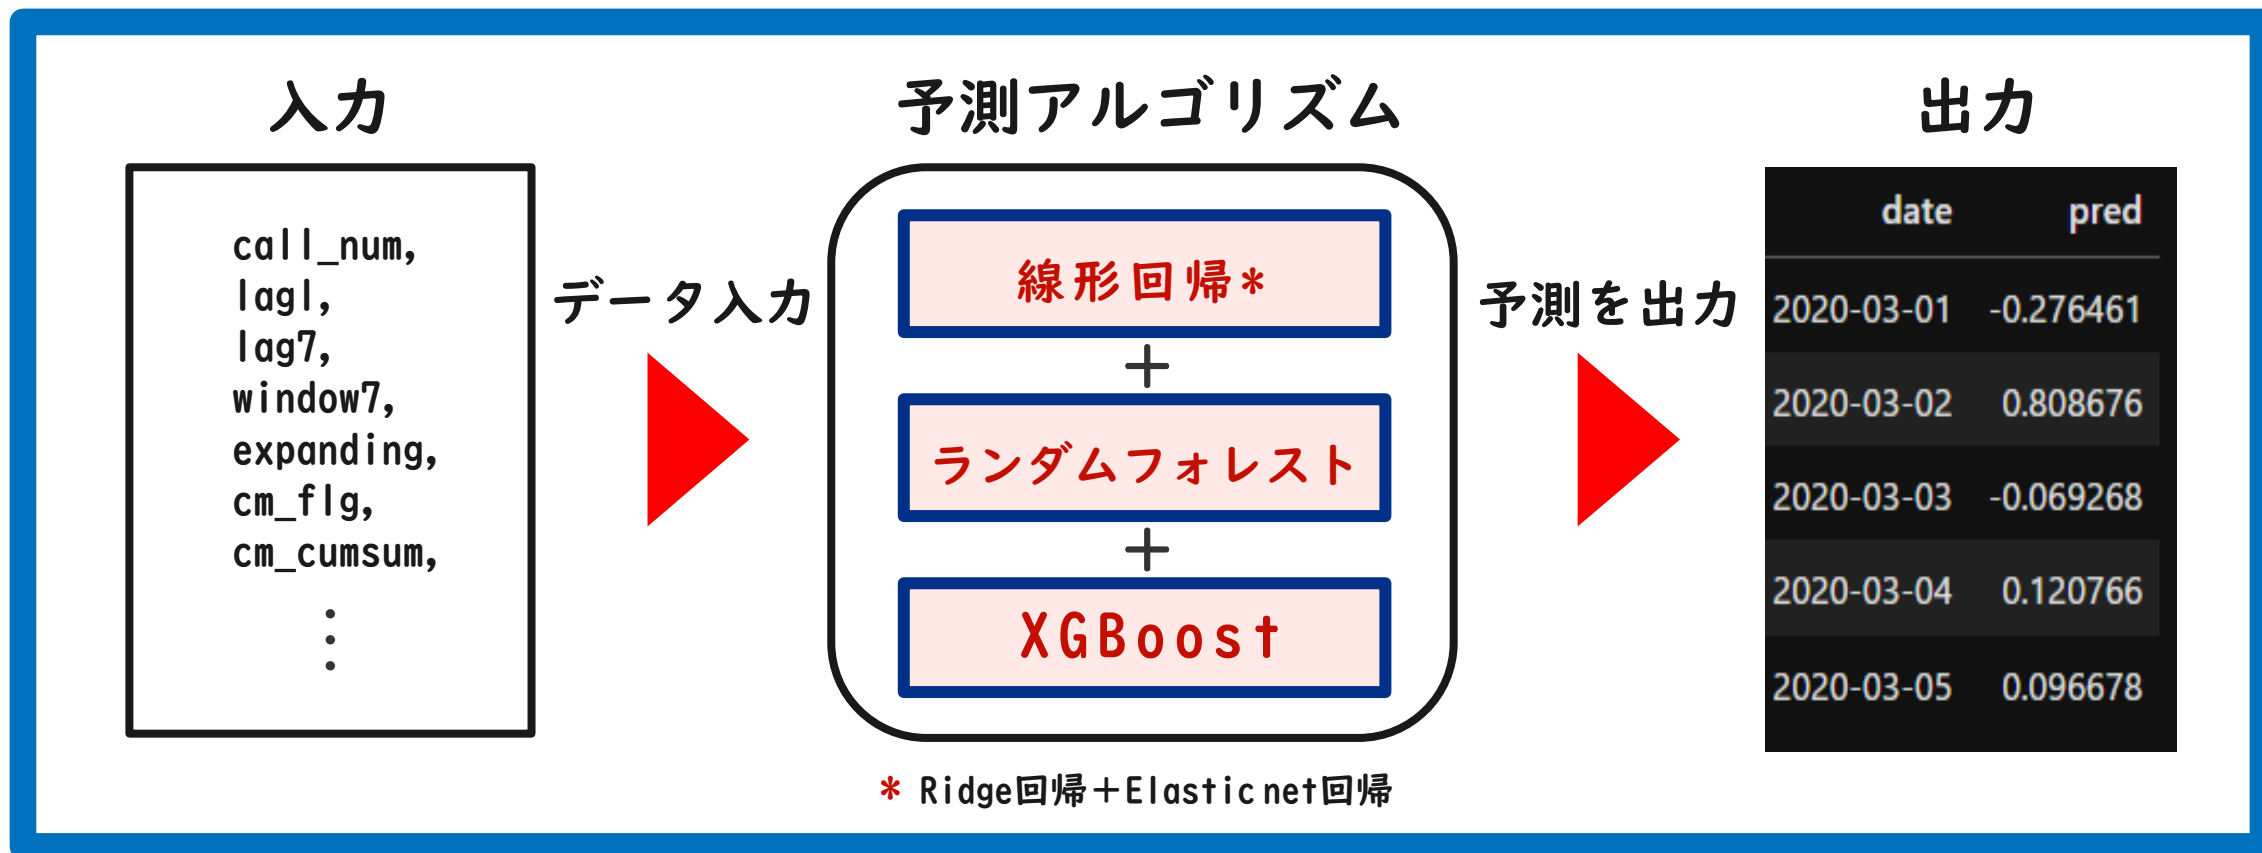


#	Column		
0	call_num		
1	acc_get_cnt		
2	acc_get_cnt_lag1	18	sin7_1
3	acc_get_cnt_lag7	19	sin7_2
4	acc_get_cnt_window7	20	sin7_3
5	acc_get_cnt_expanding	21	sin7_4
6	cm_flg	22	sin7_5
7	cm_cumsum	23	sin7_6
8	dow	24	sin7_7
9	woy	25	cos7_1
10	wom	26	cos7_2
11	doy	27	cos7_3
12	day_before_holiday_flag	28	cos7_4
13	holiday_flag	29	cos7_5
14	isSunday	30	cos7_6
15	search_AR	31	cos7_7
16	search_cnt		
17	t		

外部データ：（閲覧：2024/01/10）
Google Trend“エアレジ”検索数（人気度）
<https://trends.google.co.jp/trends/explore?date=2018-06-01%202020-03-31&geo=JP&q=%E3%82%A8%E3%82%A2%E3%83%AC%E3%82%B8&hl=ja>

実施例：予測モデルの概要


複数のアルゴリズムを組み合わせることで精度向上を目指す



モデルを複数の指標で多角的に評価するため
R2・**MAE**・**MSE**・**RMSE**の4つの評価指標を採用

実施例：1か月予測と解釈

図8 1か月予測の例
(実測値：赤線 予測値：点線)



グラフの解釈

- 全体的におおよその傾向は捉えている。
- ± 0.5 以上の上昇・下降はうまく予測。
- 0付近の予測に関してはイマイチ。

評価指標の解釈

R2 :


- モデルの適合度を示す。1に近いほどよい。
- 0.6以上なので中程度のモデルの適合度。

MAE/MSE/RMSE :

- 誤差の大きさを示す。0に近いほどよい。
- すべて小数なので誤差は小さいといえる。

実施例：3か月予測

図9 3か月予測の例
(実測値：赤線 予測値：点線)



同様にして

2020年1月1日～2020年3月31日
の3か月予測を実施

評価指標は下がっているが
概ね傾向は捉えている(図9)

そのほか

- ・ 24時間～1週間などの短期
 - ・ 半年～1年などの長期
- も予測可能

サービスのご説明

様々な期間における予測モデルをご提供
CMの効果を最大限引き出します

短期予測モデル
(24時間～1週間)

急激な変動にも対応

中期予測モデル
(1か月～3か月)

基本的な傾向を知る

長期予測モデル
(半年～1年)

大まかな傾向を捉える

さらに…

- ・ 毎日データを自動で更新
- ・ 毎週モデルをアップデート

最新のトレンドにも対応いたします

ご提供するモデルの選定

評価指標として下記のカスタム指標を定義

$$metrics = R2 \times 100 - (MAE + RMSE)$$
$$-\infty < metrics \leq 100$$

予測期間別に最も値が大きいモデルをご提供

1 か月予測の評価指標

R2	=	0.684
MAE	=	0.203
MSE	=	0.081
RMSE	=	0.285

指標の計算例：

例として1 か月予測の値を使って計算

$$metrics = 0.684 \times 100 - (0.203 + 0.285)$$
$$\doteq 67.9$$

参考文献

世界のモバイルPOS市場の動向：

- ・ Point-of-Sale Terminal Market Size, Share & Trends Analysis Report By Product (Fixed, Mobile), By Component (Hardware, Software), By Deployment (Cloud, On-premise), By End-use (Healthcare, Retail), And Segment Forecasts, 2023 - 2030

<https://www.grandviewresearch.com/industry-analysis/point-of-sale-pos-terminals-market> (2024/01/13)

- ・ Mobile POS Terminals Market Size, Share & Trends Analysis Report By Component (Hardware, Software, Service), By Type (Tablets, Others), By Application (Restaurants, Hospitality, Healthcare, Retail), By Region, And Segment Forecasts, 2023 - 2030

<https://www.grandviewresearch.com/industry-analysis/mobile-pos-terminals-market> (2024/01/13)

国内企業のモバイルPOSに対する認識：

- ・ 【調査レポート】 大手企業でモバイルPOSが拡大する兆し企業規模別に見た、モバイルPOS導入検討状況

https://jpn.nec.com/mobile-pos/mobile_pos_intention_survey.html (2024/01/02)

予測モデル構築：

- ・ Kaggleで磨く機械学習の実践力（著：諸橋 政幸）
- ・ Pythonによる時系列分析 予測モデル構築と企業事例（著：高橋 威知郎）
- ・ Pythonで時系列解析・超入門（その12）テーブルデータ系モデルで複数先予測（正則化項付き線形回帰）

<https://www.salesanalytics.co.jp/datascience/datascience130/>

- ・ Pythonで時系列解析・超入門（その14）テーブルデータ系モデルで複数先予測（ランダムフォレスト）

<https://www.salesanalytics.co.jp/datascience/datascience132/>

- ・ Pythonで時系列解析・超入門（その15）テーブルデータ系モデルで複数先予測（XGBoost）

<https://www.salesanalytics.co.jp/datascience/datascience133/>